

Data Science and Management
SKD02 Kolloquium & Abschlussarbeit
Prof. Dr. Daniel Ambach

**Bedingte Energieeffizienz von Spiking Neural Networks: Eine
Kipppunkt-Analyse gegenüber quantisierten Transformer-
Modellen auf SST-2**

Exposé zur Bachelorarbeit

Eingereicht von	Max Trummer
Matrikelnummer:	200028
Datum:	30. Juli 2026

Inhaltsverzeichnis

Zusammenfassung.....	2
1 Problemstellung und Relevanz.....	2
2 Zielsetzung.....	3
3 Forschungsfrage und Hypothesen.....	3
3.1 Forschungsfrage.....	3
3.2 Hypothesen.....	3
4 Forschungsstand und wissenschaftliche Vorarbeiten.....	4
5 Forschungsdesign und Methode.....	5
5.1 Arbeitsform.....	5
5.2 Vorgehen.....	5
5.3 Annahmen und Grenzen.....	5
6 Praktischer Nutzen.....	5
7 Grobgliederung der Arbeit.....	6
8 Zeitplan.....	6
Quellenverzeichnis.....	6

Zusammenfassung

Spiking Neural Networks (SNNs) gelten in der Theorie als energieeffiziente Alternative zu klassischen tiefen Netzen. Diese Arbeit prüft diese Behauptung für die Sentimentklassifikation auf SST-2 und zeigt, dass der Energievorteil nicht bedingungslos gilt, sondern von der Energie pro Spike der Zielhardware und der Rechenpräzision des Transformer-Vergleichsmodells (FP32 oder INT8) abhängt. Auf Basis eigener Experimente mit sechs parametervergleichbaren Modellen (1 bis 5 Mio. Parameter) wird der Kippunkt bestimmt, ab dem sich der Vorteil dreht: Gegenüber FP32 ist das SNN durchgängig effizienter (Faktor rund 164 bis 201 je nach Modellpaarung), gegenüber INT8 kippt der Vorteil bereits bei rund 7 bis 9 pJ pro Spike und damit unterhalb der Werte dokumentierter neuromorpher Chips wie Intel Loihi (23,6 pJ pro synaptischer Operation). Das Ergebnis wird als Effizienz-Landkarte aufbereitet, die Deployment-Entscheidungen zwischen neuromorpher Hardware und quantisierten Standardmodellen unterstützt.

1 Problemstellung und Relevanz

Die Energiekosten des maschinellen Lernens sind zu einem eigenständigen Forschungs- und Kostenthema geworden (Strubell, Ganesh & McCallum, 2019; Patterson et al., 2021). Im produktiven Betrieb dominiert nicht das einmalige Training, sondern die millionenfach anfallende Inferenz die laufenden Kosten; auf Edge-Geräten wird die Energie pro Inferenz zusätzlich zu einer harten Batterierestriktion. Als Antwort werden SNNs in Verbindung mit neuromorpher Hardware regelmäßig als besonders energieeffizient positioniert (Roy, Jaiswal & Panda, 2019), inzwischen auch für NLP-Aufgaben (Zhu et al., 2023; Lv et al., 2023; Bal & Sengupta, 2024).

Diese Effizienzversprechen stehen jedoch zunehmend in der Kritik: Auf gleicher digitaler Hardware sind ratencodierte SNNs oft nicht effizienter als klassische Netze (Davidson & Furber, 2021; Dampfhoffer et al., 2023), und der Vorteil hängt an niedrigen Spike-Raten (Yan, Bai & Wong, 2024). Zudem wird der SNN-Vorteil häufig gegen unquantisierte FP32-Modelle gerechnet, obwohl INT8-Quantisierung bei Transformern längst Stand der Technik ist (Zafrir et al., 2019; Kim et al., 2021). Damit fehlt eine transparente, quantitative Antwort darauf, unter welchen Hardware- und Präzisionsbedingungen sich ein SNN gegenüber einem quantisierten Transformer tatsächlich lohnt. Diese Lücke adressiert die Arbeit mit einem anwendungsorientierten, datenbasierten Ansatz, der zum Profil des Studiengangs Data Science and Management passt: Es geht nicht um neue Lernverfahren, sondern um eine belastbare Entscheidungsgrundlage für Deployment- und Investitionsentscheidungen.

2 Zielsetzung

Ziel ist es, den Energievorteil von SNNs gegenüber Transformern für die Sentimentklassifikation auf SST-2 zu konditionieren statt zu pauschalisieren. Die Arbeit weist auf Basis eigener Experimente nach, dass parametervergleichbare SNN- und Transformer-Modelle (1 bis 5 Mio. Parameter) eine vergleichbare Klassifikationsgüte erreichen, erfasst die Rechenlast beider Architekturen in hardwareunabhängigen Operationszahlen (synaptische Operationen, SynOps, gegenüber Multiply-Accumulate-Operationen, MACs) und bestimmt über ein transparentes Energiemodell den Kipppunkt, ab dem der SNN-Vorteil gegenüber FP32- und INT8-Transformern kippt. Das Ergebnis wird als Effizienz-Landkarte über Energie pro Spike und Rechenpräzision dargestellt und mit dokumentierten neuromorphen Chips verortet.

3 Forschungsfrage und Hypothesen

3.1 Forschungsfrage

Unter welchen Bedingungen, charakterisiert durch die Energie pro Spike der Zielhardware und die Rechenpräzision des Vergleichsmodells (FP32 oder INT8), ist ein Spiking Neural Network bei der Sentimentklassifikation auf SST-2 energieeffizienter als ein parametervergleichbarer Transformer, und bei welcher Energie pro Spike liegt der Kipppunkt?

3.2 Hypothesen

Daraus ergeben sich zwei gerichtete, über die Messdaten prüfbare Hypothesen. H1: Gegenüber einem FP32-Transformer ist das SNN über den gesamten dokumentierten Bereich der Energie pro Spike (0,9 bis 45 pJ) effizienter, bei 0,9 pJ um mehr als zwei Größenordnungen. H2: Gegenüber einem INT8-Transformer kippt der Vorteil bei rund 7 bis 9 pJ pro Spike; auf dokumentierter digitaler neuromorpher Hardware (Loihi 23,6 pJ; TrueNorth 26 pJ) ist der INT8-Transformer folglich energieeffizienter.

4 Forschungsstand und wissenschaftliche Vorarbeiten

Die Standardreferenz für Energiekosten elementarer Operationen ist Horowitz (2014): In 45-nm-Technologie kostet ein FP32-MAC rund 4,6 pJ, ein INT8-MAC rund 0,23 pJ. Für SNNs haben Lemaire et al. (2022) die Zahl spikegetriebener synaptischer Ereignisse (SynOps) als hardwareunabhängiges Gegenstück zur MAC-Zahl etabliert; das NeuroBench-Framework (Yik et al., 2025) fordert solche fairen, hardwareunabhängigen Vergleiche. Dokumentierte

digitale neuromorphe Chips liegen bei 23,6 pJ pro synaptischer Operation (Loihi, Davies et al., 2018; zur Nachfolgegeneration Loihi 2 vgl. Orchard et al., 2021) bzw. 26 pJ pro synaptischem Ereignis (TrueNorth, Merolla et al., 2014). Ein früher digitaler IBM-Prototyp derselben Linie lag bei 45 pJ pro Spike (Merolla et al., 2011); analoge und Mixed-Signal-Designs stellen dagegen Sub-pJ-Werte in Aussicht, sind aber nicht produktreif. Daraus ergibt sich ein Untersuchungsbereich von etwa 0,9 pJ (optimistisches analoges Szenario) bis 45 pJ (früher Prototyp) pro Spike, wobei die belegten Chips Loihi (23,6 pJ) und TrueNorth (26 pJ) als Ankerpunkte dienen.

Die Effizienzdebatte ist offen: Befürworter argumentieren mit ereignisgetriebener, spärlicher Berechnung (Roy et al., 2019), während kritische Arbeiten zeigen, dass SNNs auf identischer digitaler Hardware oft nicht effizienter sind (Davidson & Furber, 2021; Dampfhofer et al., 2023) und nur unterhalb bestimmter Spike-Raten gewinnen (Yan et al., 2024). Spikende Sprachmodelle wie SpikeGPT, SpikeBERT und SpikingBERT (Zhu et al., 2023; Lv et al., 2023; Bal & Sengupta, 2024) berichten Einsparungen, rechnen diese aber überwiegend gegen FP32-Baselines. Gleichzeitig ist INT8-Quantisierung für Transformer mit minimalem Genauigkeitsverlust etabliert (Zafir et al., 2019; Kim et al., 2021) und damit die realistische Vergleichsbasis. Als Benchmark dient SST-2 (Socher et al., 2013) aus dem GLUE-Benchmark (Wang et al., 2019) und ist etabliert und klein genug für Modelle im Bereich von 1 bis 5 Mio. Parametern.

Es fehlt bislang eine Arbeit, die für einen etablierten NLP-Benchmark mit größenvergleichbaren, selbst trainierten Modellen den Kipppunkt des SNN-Vorteils als Funktion der Energie pro Spike und der Transformer-Präzision explizit bestimmt und als Entscheidungsinstrument aufbereitet. Genau hier setzt die Arbeit an.

Eigene Vorarbeiten liegen bereits vor: Sechs Modelle (drei SNNs, drei Transformer, 1 bis 5 Mio. Parameter) wurden auf SST-2 trainiert und auf dem Dev-Set evaluiert und erreichen vergleichbare Genauigkeit (rund 79 bis 84 %). Das Verhältnis von MACs zu SynOps liegt bei parametergleicher Paarung zwischen 32 und 39. Bei 0,9 pJ pro Spike ist das kleinste SNN rund 185-mal sparsamer als der FP32-Transformer und noch rund 9-mal sparsamer als der INT8-Transformer; der Kipppunkt gegenüber INT8 liegt bei rund 7 bis 9 pJ pro Spike. Diese Werte stammen aus einem ersten, rein operationsbasierten Durchlauf; die Hauptstudie erweitert das Modell um Speicherzugriffe und Zeitschritte, was den Kipppunkt voraussichtlich nach unten verschiebt, und bereitet die Ergebnisse als Effizienz-Landkarte auf.

5 Forschungsdesign und Methode

5.1 Arbeitsform

Gewählt wird die Arbeitsform des datenbasierten Reports (15 bis 20 Seiten): Der Erkenntnisgewinn entsteht aus der systematischen Auswertung eigener quantitativer Messdaten in Verbindung mit einem literaturbasierten Energiemodell. Diese Einordnung ist mit der Betreuung noch zu bestätigen.

5.2 Vorgehen

Das methodische Vorgehen umfasst fünf Schritte. Zunächst werden parametergleiche SNNs und Transformer auf SST-2 trainiert und auf dem Dev-Set evaluiert; dieser Modellvergleich ist bereits abgeschlossen. Anschließend werden die SynOps und MACs pro Inferenz gemessen und das Verhältnis R je Paarung bestimmt. Auf dieser Basis modelliert ein hardwarebewusstes Energiemodell die Energie pro Inferenz nicht nur aus den Rechenoperationen, sondern zusätzlich aus den Speicherzugriffen für Gewichte und Zustände, die beim SNN über alle Zeitschritte anfallen; die Rechenkosten werden nach Horowitz (2014) mit 4,6 pJ pro FP32-MAC und 0,23 pJ pro INT8-MAC auf einem einheitlichen Technologieknoten angesetzt. Für einen fairen Vergleich wird auch das SNN INT8-quantisiert. In der anschließenden Kippunkt- und Sensitivitätsanalyse werden sowohl die Energie pro Spike über 0,9 bis 45 pJ als auch die Zahl der Zeitschritte variiert; der Kippunkt wird primär für die Paarung nach gleicher Genauigkeit und ergänzend für die Paarung nach gleicher Parameterzahl berichtet. Abschließend werden die Ergebnisse als Effizienz-Landkarte über Energie pro Spike und Rechenpräzision visualisiert und dokumentierte Chips wie Loihi und TrueNorth darin verortet.

5.3 Annahmen und Grenzen

Auch das hardwarebewusste Energiemodell bleibt eine Abschätzung: Es stützt sich auf publizierte Energiewerte pro Operation und pro Speicherzugriff eines Technologieknotens, nicht auf Messungen realer Chips. Weitere Grenzen, etwa die Beschränkung auf ein bis zwei Aufgaben, kleine Modelle und eine analytische statt gemessene Energieprojektion, werden im Report transparent offengelegt.

6 Praktischer Nutzen

Die Arbeit liefert eine Entscheidungsgrundlage für energie- und kosteneffizientes Deployment von NLP-Modellen. Mit der Effizienz-Landkarte können ML- und Plattform-

Teams für gegebene Zielhardware ablesen, ob sich ein SNN gegenüber einem INT8-Transformer lohnt, statt einem pauschalen Versprechen zu folgen; für Hardware- und Investitionsentscheidungen liefert der Kippunkt (rund 7 bis 9 pJ pro Spike) eine konkrete Anforderungsgröße an neuromorphe Beschaffung. Für Green-AI- und Nachhaltigkeitsberichte bietet die Methodik zudem ein transparentes, reproduzierbares Schema, um Energieaussagen über Architekturen hinweg zu prüfen, und trägt zu einer faireren Bewertung von SNNs gegenüber dem realistischen Stand der Technik bei.

7 Grobgliederung der Arbeit

Die Arbeit gliedert sich in sechs Kapitel. Die Einleitung führt Problemstellung, Relevanz, Forschungsfrage und Aufbau ein. Das Kapitel Grundlagen und Forschungsstand behandelt SNNs und Transformer, Energiemodelle, neuromorphe Hardware, die Effizienzdebatte und die Quantisierung. Das Methodenkapitel beschreibt Datensatz, Modelle, Operationsmetriken, Energiemodell sowie Kippunkt- und Sensitivitätsanalyse. Das Ergebniskapitel stellt Klassifikationsgüte, Operationszahlen, Kippunkte und die Effizienz-Landkarte dar. Die Diskussion ordnet die Ergebnisse in die Literatur ein und behandelt Paarungsstrategien, Limitationen und Implikationen für Deployment-Entscheidungen. Den Abschluss bilden Fazit und Ausblick.

8 Zeitplan

Nach Abstimmung des Konzepts mit der Betreuung ist für die Bearbeitung ein Zeitraum von zwölf Wochen vorgesehen: Literaturvertiefung und Grundlagenkapitel (Wochen 1 bis 2), Konsolidierung der Experimente sowie Sensitivitäts- und Kippunktanalysen inklusive Effizienz-Landkarte (Wochen 3 bis 5), Ergebnis- und Methodenkapitel (Wochen 6 bis 8), Einleitung, Diskussion und Fazit sowie Gesamtrevision (Wochen 9 bis 11) und ein Puffer für Endkorrektur und Abgabe (Woche 12). Die konkreten Termine werden an die Fristen der DBU angepasst.

Quellenverzeichnis

- Bal, M., & Sengupta, A. (2024). SpikingBERT: Distilling BERT to train spiking language models using implicit differentiation. *Proceedings of the AAAI Conference on Artificial Intelligence*, 38(10), 10998-11006.
- Dampfhofer, M., Mesquida, T., Valentian, A., & Anghel, L. (2023). Are SNNs really more energy-efficient than ANNs? An in-depth hardware-aware study. *IEEE Transactions on Emerging Topics in Computational Intelligence*, 7(3), 731-741.
- Davidson, S., & Furber, S. B. (2021). Comparison of artificial and spiking neural networks on digital hardware. *Frontiers in Neuroscience*, 15, 651141.
- Davies, M., Srinivasa, N., Lin, T.-H., China, G., Cao, Y., Choday, S. H., ... Wang, H. (2018). Loihi: A neuromorphic manycore processor with on-chip learning. *IEEE Micro*, 38(1), 82-99.
- Horowitz, M. (2014). 1.1 Computing's energy problem (and what we can do about it). 2014 IEEE International Solid-State Circuits Conference (ISSCC), 10-14.
- Kim, S., Gholami, A., Yao, Z., Mahoney, M. W., & Keutzer, K. (2021). I-BERT: Integer-only BERT quantization. *Proceedings of the 38th International Conference on Machine Learning (ICML)*, PMLR 139, 5506-5518.
- Lemaire, E., Cordone, L., Castagnetti, A., Novac, P.-E., Courtois, J., & Miramond, B. (2022). An analytical estimation of spiking neural networks energy efficiency. In *Neural Information Processing (ICONIP 2022)*. Springer.
- Lv, C., Li, T., Xu, J., Gu, C., Ling, Z., Zhang, C., Zheng, X., & Huang, X. (2023). SpikeBERT: A language Spikformer learned from BERT with knowledge distillation. *arXiv:2308.15122*.
- Merolla, P., Arthur, J., Akopyan, F., Imam, N., Manohar, R., & Modha, D. S. (2011). A digital neurosynaptic core using embedded crossbar memory with 45pJ per spike in 45nm. 2011 IEEE Custom Integrated Circuits Conference (CICC), 1-4.
- Merolla, P. A., Arthur, J. V., Alvarez-Icaza, R., Cassidy, A. S., Sawada, J., Akopyan, F., ... Modha, D. S. (2014). A million spiking-neuron integrated circuit with a scalable communication network and interface. *Science*, 345(6197), 668-673.
- Orchard, G., Frady, E. P., Rubin, D. B. D., Sanborn, S., Shrestha, S. B., Sommer, F. T., & Davies, M. (2021). Efficient neuromorphic signal processing with Loihi 2. 2021 IEEE Workshop on Signal Processing Systems (SiPS), 254-259.

- Patterson, D., Gonzalez, J., Le, Q., Liang, C., Munguia, L.-M., Rothchild, D., So, D., Texier, M., & Dean, J. (2021). Carbon emissions and large neural network training. arXiv:2104.10350.
- Roy, K., Jaiswal, A., & Panda, P. (2019). Towards spike-based machine intelligence with neuromorphic computing. *Nature*, 575(7784), 607-617.
- Socher, R., Perelygin, A., Wu, J., Chuang, J., Manning, C. D., Ng, A., & Potts, C. (2013). Recursive deep models for semantic compositionality over a sentiment treebank. *Proceedings of EMNLP 2013*, 1631-1642.
- Strubell, E., Ganesh, A., & McCallum, A. (2019). Energy and policy considerations for deep learning in NLP. *Proceedings of the 57th Annual Meeting of the ACL*, 3645-3650.
- Wang, A., Singh, A., Michael, J., Hill, F., Levy, O., & Bowman, S. R. (2019). GLUE: A multi-task benchmark and analysis platform for natural language understanding. *ICLR*.
- Yan, Z., Bai, Z., & Wong, W.-F. (2024). Reconsidering the energy efficiency of spiking neural networks. arXiv:2409.08290.
- Yik, J., Van den Berghe, K., den Blanken, D., Bouhadjar, Y., Fabre, M., Hueber, P., ... et al. (2025). The NeuroBench framework for benchmarking neuromorphic computing algorithms and systems. *Nature Communications*, 16.
- Zafir, O., Boudoukh, G., Izsak, P., & Wasserblat, M. (2019). Q8BERT: Quantized 8bit BERT. *5th Workshop on Energy Efficient Machine Learning and Cognitive Computing (EMC2)*, NeurIPS 2019.
- Zhu, R.-J., Zhao, Q., Li, G., & Eshraghian, J. K. (2023). SpikeGPT: Generative pre-trained language model with spiking neural networks. arXiv:2302.13939.